Zdanie 2c

Kardash Andriy

November 2026

1 Zadanie 2c

Je daných aspoň 20 miest (20 – 40) a každé má určené súradnice ako celé čísla X a Y . Tieto súradnice sú náhodne vygenerované. (Rozmer mapy môže byť napríklad 200 * 200 km.) Cena cesty medzi dvoma mestami zodpovedá Euklidovej vzdialenosti – vypočíta sa pomocou Pytagorovej vety. Celková dĺžka trasy je daná nejakou permutáciou (poradím) miest. Cieľom je nájsť takú permutáciu (poradie), ktorá bude mať celkovú vzdialenosť čo najmenšiu.

Na riešenie tejto úlohy používam dve metódy.

- Genetický algoritmus
- Simulované žíhanie

2 Genetický algoritmus

Metóda hľadania a optimalizácie napodobňujúca prirodzený výber. Algoritmus nepracuje s jedným riešením, ale hneď s celou generáciou. Z generácie na generáciu sa najlepšie jedince prenášajú do nasledujúcich generácií, krížia sa, mutujú a tak postupne nachádzajú lepšie riešenia (v najlepšom prípade globálny extrém).

Tento algoritmus nezaručuje nájdenie optimálneho riešenia (globálneho extrému)!

2.1 Popis fungovania algoritmu

1. Úvodné údaje
Na mape s rozmermi 200×200 sa náhodne vygeneruje 20–40 miest s jedinečnými celočíselnými súradnicami. Aby bolo možné výsledok reprodukovať, používa sa seed = 42.

```
def generate_cities(count:int):
    if count < 20 or count > 40:
        raise ValueError("count must be between 20 and 40")
    cities = []
    for i in range(count):
        x = random.randrange(0, MAP_SIZE)
        y = random.randrange(0, MAP_SIZE)
        while (x,y) in cities:
            x = random.randrange(0, MAP_SIZE)
            y = random.randrange(0, MAP_SIZE)
        cities.append((x,y))
    return cities
```

Následne sa vytvorí matica vzdialeností medzi všetkými mestami. Vzdialenosť sa počíta podľa euklidovskej metriky. Matica je symetrická, preto vzdialenosť medzi všetkými dvojicami vypočítavame len raz. Je to potrebné na to, aby sa algoritmus mohol priamo obrátiť na maticu vzdialeností a získať z nej vzdialenosť, aby ju nemusel vypočítavať zakaždým nanovo.

```
def euclidean(x:tuple, y:tuple):
    return sqrt((x[0] - y[0])**2 + (x[1] - y[1])**2)



def distance_matrix(cities:list):
    count = len(cities)
    dist = [[0.0] * count for _ in range(count)]
    for i in range(count):
        for j in range(i + 1, count):
            d = euclidean(cities[i], cities[j])
            dist[i][j] = d
            dist[j][i] = d
    return dist
```

2. Predstavenie riešenia
Každý jedinec (chromosóma) predstavuje permutáciu indexov miest, teda poradie, v akom ich cestovateľ navštevuje. Trasa je uzavretá, z posledného mesta sa cestovateľ vracia do prvého.

3. Počiatočná populácia
Vytvorí sa 100 náhodných permutácií (random.shuffle). To zabezpečuje veľkú rozmanitosť na začiatku.

```
def generate_population(count:int, size:int = 100):
    population = []
    for i in range(size):
        individual = list(range(count))
        random.shuffle(individual)
        population.append(individual)
    return population
```

4. Hodnotenie jednotlivcov

- Dĺžka trasy je súčet vzdialeností medzi susednými mestami v permutácii, vrátane hrany (posledné → prvé).
- Fitness = 1 / dĺžka. Čím je trasa kratšia, tým je fitness vyššia. Úloha minimalizácie dĺžky sa tak premenila na úlohu maximalizácie fitness.

5. Selekcia
Boli implementované dva spôsoby výberu rodičov:

- **Turnajová selekcia** náhodne sa vyberú n jedinci, vyhráva ten, kto má najvyššiu fitness. Selekčný tlak sa reguluje veľkosťou turnaja.
- **Ruleta** pravdepodobnosť výberu jedinca je úmerná jeho fitness. Vygeneruje sa náhodné číslo z intervalu ⟨0, súčet fitness⟩ a jedinci sa hromadia, kým súčet neprekročí toto číslo.

6. Kríženie
Používa sa varianta usporiadaného kríženia (Order Crossover, OX):

- V prvom rodiči sa náhodne vyberie úsek ⟨l, r⟩ a bez zmien sa skopíruje do potomka na tie isté pozície.
- Zvyšné pozície sa vyplnia mestami z druhého rodiča v tom poradí, v akom sa tam nachádzajú. Mestá, ktoré sa už nachádzajú v skopírovanom úseku, sa preskočia a samotný úsek sa "preskočí".

7. Mutácia
S pravdepodobnosťou 30 % sa na potomka uplatní inverzná mutácia: vyberie sa náhodný úsek trasy ⟨l, r⟩ a poradie miest v ňom sa obráti. Mutácia podporuje rozmanitosť populácie a pomáha dostať sa z lokálneho minima.

```
def mutate(ind:list):
    individual = list(ind)
    l, r = sorted(random.sample(range(len(individual)), 2))
    opa = []
    for i in range(l, r+1):
        opa.append(individual[i])
    opa.reverse()
    for i in range(len(opa)):
        individual[l+i] = opa[i]
    return individual
```

8. Formovanie novej generácie (elitárstvo)
Populácia sa triedi podľa dĺžky trasy. Dvaja najlepší jedinci (elita) prechádzajú do novej generácie bez zmien. Zvyšné miesta sa zapĺňajú potomkami získanými prostredníctvom selekcie, kríženia a mutácie. Vďaka elitárstvu sa najlepšie nájdené riešenie nikdy nestratí, takže dĺžka najlepšej trasy sa z generácie na generáciu nezvyšuje.

9. Podmienka ukončenia
Algoritmus sa ukončí, keď nastane jedna z dvoch situácií:

- bolo dosiahnutých 1000 generácií.
- počas 200 generácií za sebou nebola nájdená lepšia trasa (stagnácia, "patience").

10. Riešenie
Výstupom je poradie miest a dĺžka zodpovedajúcej cesty.

2.2 Nastavenie experimentov

Spoločné nastavenia

- **Mapa:** mestá sa generujú náhodne na mriežke 200×200 s celočíselnými, navzájom rôznymi súradnicami. Generátor sa pred tvorbou mapy vždy inicializuje rovnakým seedom (`MAP_SEED = 42`). Pre daný počet miest preto všetky experimenty pracujú s identickou mapou a rozdiely vo výsledkoch spôsobujú len parametre algoritmu.
- **Opakovania:** genetický algoritmus je stochastický, preto sa každá konfigurácia spúšťa 10-krát so seedmi $0, \ldots, 9$. Uvádzané hodnoty sú priemery cez týchto 10 behov. Rovnaké seedy pri rôznych konfiguráciách zaručujú férové porovnanie.
- **Ukončenie behu:** najviac 1000 generácií, alebo skôr, ak sa najlepšie riešenie nezlepší počas 200 generácií po sebe (patience).
- **Reprezentácia a operátory** sú vo všetkých experimentoch rovnaké: jedinec je permutácia miest, kríženie je modifikovaný order crossover (OX), mutácia je inverzia náhodného úseku trasy (ťah 2-opt), fitness je 1/dĺžka trasy.
- **Opakované využitie behov:** fakticky totožné konfigurácie sa nepočítajú znova. Ruleta nemá parameter k a baseline konfigurácia sa spočíta iba raz pre všetky experimenty, v ktorých sa vyskytuje. Spolu ide o 36 unikátnych konfigurácií, teda 360 behov GA.

Základná konfigurácia (baseline)

V experimentoch sa vždy mení iba jeden parameter, ostatné ostávajú na hodnotách z tabuľky 1 (metóda *one factor at a time*).

Parameter	Hodnota
Počet miest	30
Veľkosť populácie	100
Pravdepodobnosť mutácie	0,3
Počet elitných jedincov	2
Veľkosť turnaja k	3
Max. počet generácií / patience	1000 / 200
Selekcia	turnaj aj ruleta

Table 1: Základná konfigurácia genetického algoritmu

Hlavné experimenty

1. **Turnaj vs. ruleta.** Priame porovnanie oboch metód výberu rodičov pri baseline nastaveniach na mape s 30 mestami. Sleduje sa výsledná dĺžka trasy, priebeh konvergencie a tvar najlepšej nájdenej trasy.

2. **Veľkosť turnaja k a selekčný tlak.** GA s turnajovou selekciou sa spúšťa pre $k \in \{2, 3, 5, 10, 20\}$. Selekčný tlak sa navyše meria samostatne, mimo behu GA, aby výsledok neovplyvnilo kríženie ani mutácia. Na mape s 30 mestami sa vygeneruje jedna náhodná populácia veľkosti $n = 100$ a zoradí sa podľa dĺžky trasy (poradie 1 = najkratšia). Z nej sa každou metódou (turnaj pre všetky uvedené k a ruleta) 100 000-krát vyberie rodič a zaznamená sa jeho poradie. Namerané početnosti sa porovnávajú s teoretickou pravdepodobnosťou:

$$P_{\text{turnaj}}(r) = \frac{\binom{n-1-r}{k-1}}{\binom{n}{k}}, \qquad P_{\text{ruleta}}(i) = \frac{f_i}{\sum_j f_j},$$

   kde $r = 0$ je najlepší jedinec (turnaj vyberá k jedincov bez opakovania).

3. **Elitizmus.** Počet elitných jedincov sa mení v rozsahu $\{0, 1, 2, 5, 10\}$, pre turnaj aj ruletu.

Doplnkové experimenty

Tieto experimenty slúžia na overenie zvolenej baseline konfigurácie a sú vyhodnotené len tabuľkami:

- pravdepodobnosť mutácie $\in \{0{,}05;\ 0{,}1;\ 0{,}3;\ 0{,}5;\ 0{,}8\}$,
- veľkosť populácie $\in \{20, 50, 100, 200\}$,
- počet miest $\in \{20, 25, 30, 35, 40\}$ (pre každý počet je to iná mapa).

Sledované metriky

Pre každú konfiguráciu sa z 10 behov počítajú:

- **avg, std, best, worst**: priemer, smerodajná odchýlka, minimum a maximum dĺžky výslednej trasy,
- **gap** [%]: o koľko percent je priemerná trasa dlhšia ako *najlepšia známa* trasa na danej mape, teda najkratšia trasa nájdená v ktoromkoľvek behu ktoréhokoľvek experimentu. Nejde o dokázané optimum.
- **gen**: priemerná generácia, v ktorej bolo nájdené najlepšie riešenie (rýchlosť konvergencie),
- **čas**: priemerný čas jedného behu v sekundách,
- **hit**: v koľkých z 10 behov algoritmus našiel najlepšiu známu trasu.

Pri grafoch priebehu cez generácie sa beh, ktorý skončil skôr (patience), doplní poslednou dosiahnutou hodnotou až do 1000. generácie, aby sa dali behy priemerovať. Vďaka elitizmu sa najlepšia hodnota po skončení behu aj tak nemení.

2.3 Výsledky a porovnanie

2.3.1 Turnaj vs. ruleta

Metrika	Turnaj	Ruleta
avg	1082,15	1272,98
std	23,36	100,27
best	1051,59	1163,92
worst	1121,16	1444,69
gap [%]	2,91	21,05
gen	124,5	898,7
čas [s]	0,39	1,35
hit	1/10	0/10

Table 2: Turnaj vs. ruleta, baseline, 30 miest (najlepšia známa trasa 1051,59)

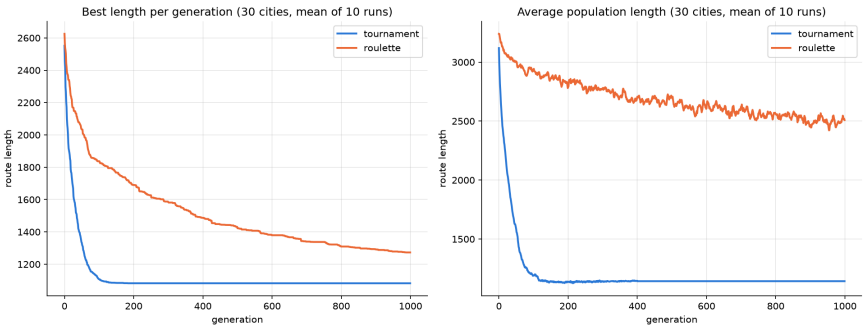


Figure 1: Najlepšia (vľavo) a priemerná (vpravo) dĺžka trasy v populácii počas generácií, priemer z 10 behov

Turnajová selekcia je vo všetkých metrikách lepšia (tabuľka 2). Priemerná trasa je o 18 % kratšia a rozptyl je viac ako štyrikrát menší.

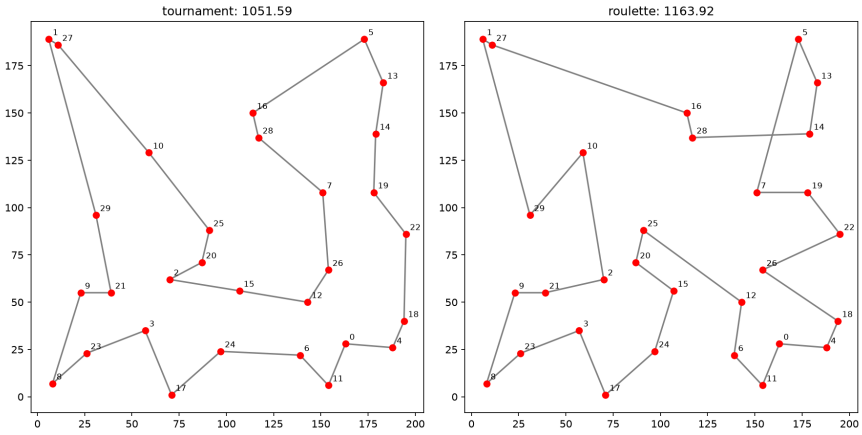


Figure 2: Najlepšia nájdená trasa každej metódy

- **Turnaj konverguje rýchlo** (obr. 1). Do približne 150 generácií dosiahne dĺžku okolo 1080 a priemer populácie klesne takmer na úroveň najlepšieho jedinca, čiže populácia skonvergovala. Behy končia skôr vďaka kritériu patience.

- **Ruleta sa zlepšuje veľmi pomaly.** Najlepšie riešenie nachádza v priemere až v 899. generácii, teda tesne pred limitom 1000, a krivka na konci stále klesá. Priemerná dĺžka populácie ostáva okolo 2500, blízko náhodných trás (približne 3200 na začiatku). Populácia sa správa takmer ako náhodné prehľadávanie. Príčinu ukazuje experiment so selekčným tlakom (časť 2.3.2).
- **Kvalita trás** (obr. 2). Najlepšia trasa turnaja (1051,59) je zároveň najlepšou známou trasou na tejto mape a nemá žiadne kríženia hrán. Najlepšia trasa rulety (1163,92) obsahuje kríženie hrán 5–7 a 28–14. Takú trasu sa dá vždy skrátiť jedným ťahom 2-opt, čiže práve našou mutáciou, takže ruleta neskončila ani v lokálnom optime.

2.3.2 Veľkosť turnaja a selekčný tlak

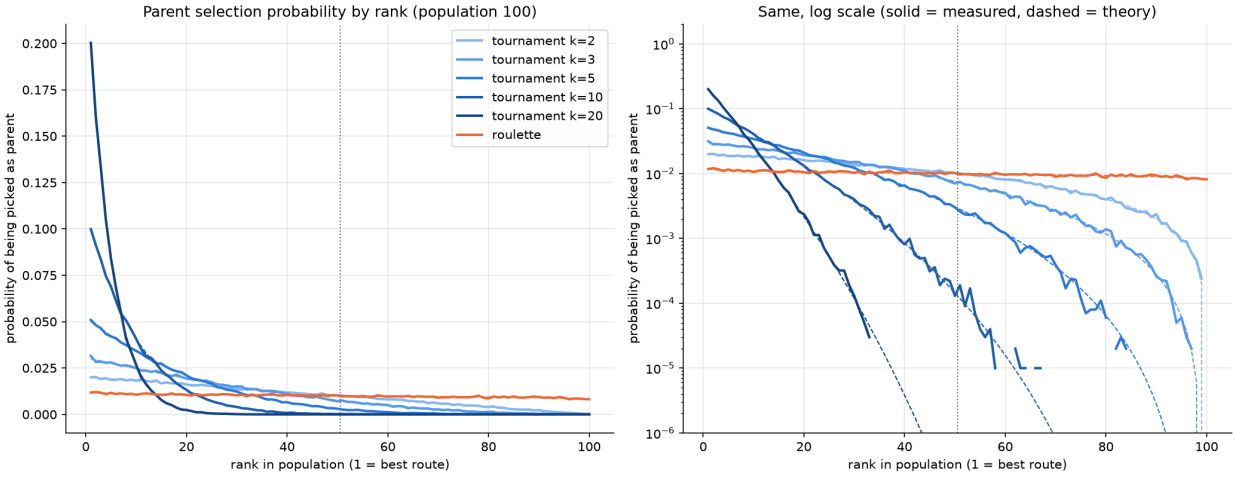


Figure 3: Pravdepodobnosť výberu jedinca za rodiča podľa poradia (populácia 100, 100 000 výberov). Plná čiara je nameraná hodnota, prerušovaná teoretická.

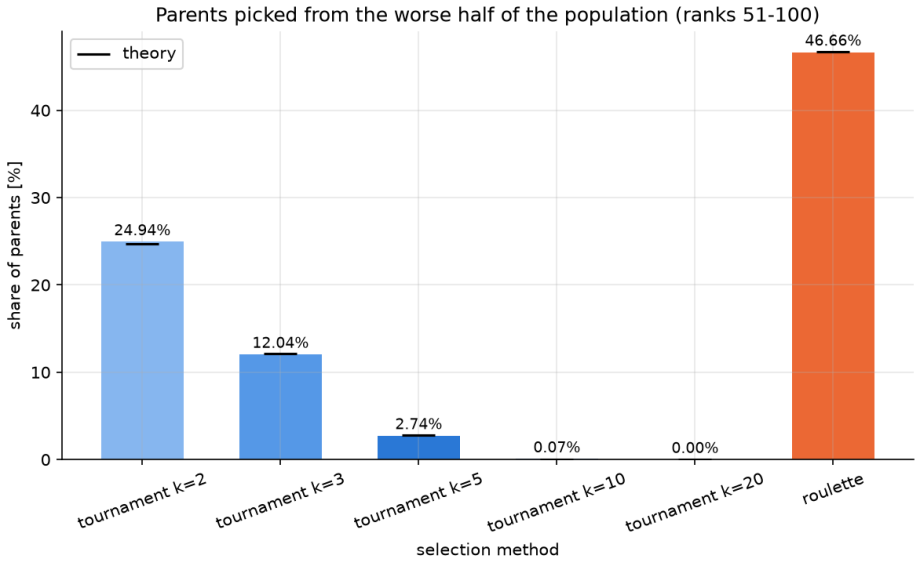


Figure 4: Podiel rodičov z horšej polovice populácie (poradia 51–100)

Metóda	Namerané [%]	Teória [%]	P(najlepší)
turnaj $k = 2$	24,941	24,747	0,02
turnaj $k = 3$	12,044	12,121	0,03
turnaj $k = 5$	2,737	2,814	0,05
turnaj $k = 10$	0,072	0,059	0,10
turnaj $k = 20$	0,000	0,000	0,20
ruleta	46,662	46,709	$\approx 0{,}012$

Table 3: Podiel rodičov vybraných z horšej polovice populácie

Namerané hodnoty sa zhodujú s teóriou pri všetkých metódach (obr. 3 vpravo, tabuľka 3). Tým je overená korektnosť implementácie oboch selekcií. Odchýlky pri zriedkavých poradiach na logaritmickej škále sú štatistický šum: pri 100 000 výberoch sa nedajú zmerať pravdepodobnosti menšie ako približne 10^{-5}.

- **Turnaj:** najlepší jedinec je vybraný s pravdepodobnosťou presne k/n. S rastúcim k prudko rastie selekčný tlak. Pri $k = 2$ pochádza ešte štvrtina rodičov z horšej polovice, pri $k = 10$ len 0,07 % a pri $k = 20$ sa horšia polovica populácie prakticky vôbec nerozmnožuje.
- **Ruleta má takmer nulový selekčný tlak.** Najlepší jedinec má šancu približne 1,2 %, najhorší 0,8 %. Z horšej polovice pochádza 46,7 % rodičov, čo je blízko 50 % pri úplne náhodnom výbere. Príčinou je fitness 1/dĺžka: trasy v populácii sa dĺžkou líšia relatívne málo, takže aj ich pravdepodobnosti výberu sú si veľmi blízke.

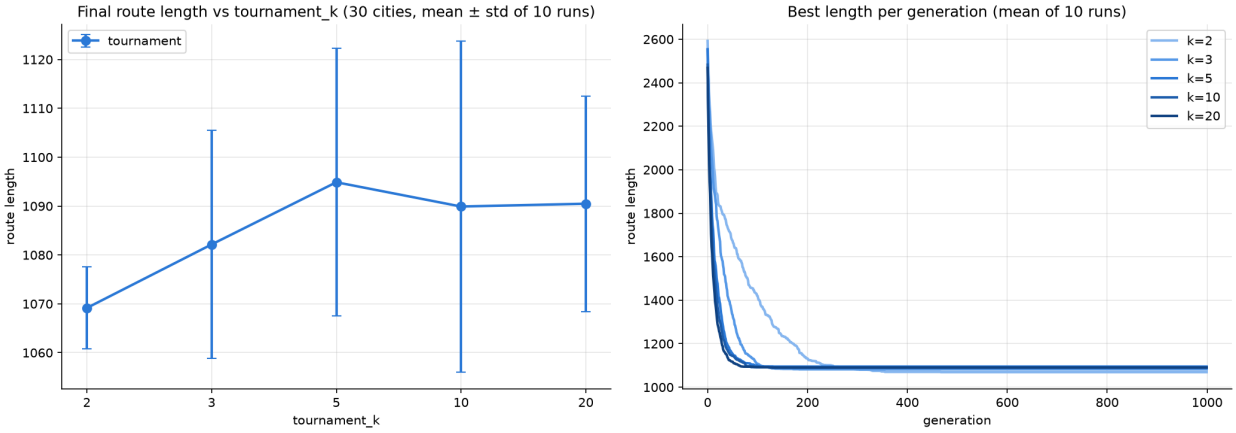


Figure 5: Výsledná dĺžka trasy (priemer ± std z 10 behov) a priebeh konvergencie pre rôzne k, 30 miest

k	avg	std	best	gap [%]	gen	hit
2	1069,15	8,41	1057,84	1,67	327,8	0/10
3	1082,15	23,36	1051,59	2,91	124,5	1/10
5	1094,88	27,38	1068,38	4,12	82,7	0/10
10	1089,91	33,89	1057,84	3,64	76,9	0/10
20	1090,48	22,03	1068,42	3,70	77,3	0/10

Table 4: Vplyv veľkosti turnaja, 30 miest

Vyšší selekčný tlak sa priamo prejavuje v správaní GA (obr. 5, tabuľka 4):

- **Väčšie k konverguje rýchlejšie.** Pri $k \geq 5$ sa najlepšie riešenie nájde v priemere okolo 80. generácie, pri $k = 2$ až okolo 330.

- **Najlepší a najstabilnejší výsledok však dáva** $k = 2$: najnižší priemer (1069,15) aj zďaleka najmenší rozptyl (8,41). Pri väčšom k sa populácia priskoro sústredí okolo niekoľkých najlepších jedincov, stratí diverzitu a uviazne v lokálnom minime (predčasná konvergencia). Slabší tlak pri $k = 2$ udrží populáciu dlhšie rôznorodú a prehľadá väčšiu časť priestoru riešení.
- Rozdiely v priemere sú malé (približne 2 %) a pri $k \geq 3$ sa intervaly smerodajných odchýlok prekrývajú. Pri 10 behoch sa teda dá spoľahlivo tvrdiť, že $k = 2$ je stabilnejšie, no poradie $k = 3$ až 20 medzi sebou nie je štatisticky preukázateľné.

2.3.3 Elitizmus

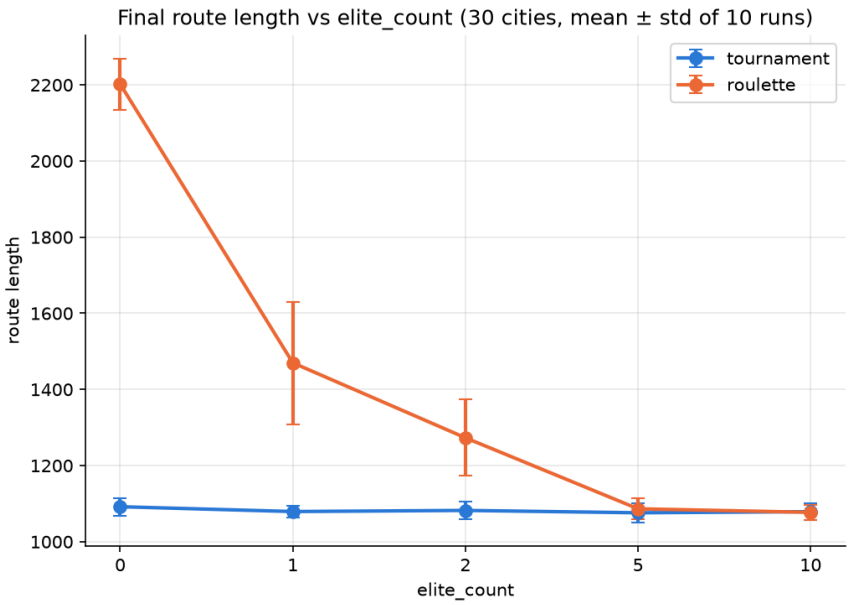


Figure 6: Výsledná dĺžka trasy v závislosti od počtu elitných jedincov, 30 miest

	Turnaj			Ruleta		
elite	**avg**	**std**	**gap [%]**	**avg**	**std**	**gap [%]**
0	1091,88	23,38	3,83	2202,12	67,21	109,41
1	1079,20	15,42	2,63	1469,92	160,83	39,78
2	1082,15	23,36	2,91	1272,98	100,27	21,05
5	1075,97	25,70	2,32	1086,44	27,99	3,31
10	1078,87	23,03	2,59	1077,13	20,29	2,43

Table 5: Vplyv elitizmu, 30 miest

- **Turnaj je na elitizmus takmer necitlivý.** Výsledok sa pohybuje v rozmedzí 1076–1092 a rozdiely sú v rámci smerodajnej odchýlky. Selekčný tlak turnaja sám udrží dobré riešenia v populácii.
- **Ruleta je od elitizmu úplne závislá** (obr. 6). Bez elity skončí na 2202 (gap 109 %), čo je len málo lepšie ako najlepšia náhodná trasa v počiatočnej populácii (približne 2550). Najlepšie riešenie nájde v priemere už v 156. generácii a potom ho stratí: bez selekčného tlaku a bez elity zaniknú dobré trasy rovnako rýchlo, ako vznikajú. S 1–2 elitnými jedincami sa výsledok výrazne zlepší, no ostáva veľký rozptyl. Pri 5 a viac elitných jedincoch dosiahne ruleta rovnakú kvalitu ako turnaj.
- **Interpretácia:** elitizmus nahrádza chýbajúci selekčný tlak rulety. Elitní jedinci sú zaručene zachovaní a zároveň sa zúčastňujú výberu rodičov, takže dobrý genetický materiál sa nestráca.

2.3.4 Doplnkové experimenty

	Turnaj			Ruleta		
mutácia	**avg**	**std**	**gen**	**avg**	**std**	**gen**
0,05	1087,08	21,20	239,5	1280,80	119,28	870,5
0,1	1094,24	24,78	179,4	1220,35	61,43	882,9
0,3	1082,15	23,36	124,5	1272,98	100,27	898,7
0,5	1080,57	17,41	208,8	1274,70	93,56	915,2
0,8	1094,98	27,76	558,0	1328,55	75,96	875,1

Table 6: Vplyv pravdepodobnosti mutácie, 30 miest

Pravdepodobnosť mutácie Pri turnaji dávajú najlepšie výsledky hodnoty 0,3 a 0,5 (tabuľka 6), čo potvrdzuje voľbu baseline hodnoty 0,3. Pri 0,3 je zároveň konvergencia najrýchlejšia (124,5 generácie). Pri 0,8 už mutácia rozbíja dobré trasy: priemer sa zhorší na 1095 a najlepšie riešenie sa nájde až okolo 558. generácie. Rozdiely medzi 0,05 a 0,5 sú však v rámci smerodajnej odchýlky. Ruleta je pri všetkých hodnotách výrazne horšia a jej výsledky sú určené hlavne slabým selekčným tlakom, nie mutáciou.

	Turnaj			Ruleta		
populácia	**avg**	**std**	**čas [s]**	**avg**	**std**	**čas [s]**
20	1106,63	31,58	0,11	1125,10	44,91	0,19
50	1081,25	17,63	0,21	1173,31	29,41	0,56
100	1082,15	23,36	0,39	1272,98	100,27	1,35
200	1075,82	22,66	0,83	1275,32	82,16	3,39

Table 7: Vplyv veľkosti populácie, 30 miest

Veľkosť populácie Pri turnaji sa výsledok zlepší z 1107 (populácia 20) na približne 1080 (populácia 50). Ďalšie zväčšovanie už takmer nepomáha (1081 → 1076), no čas behu rastie približne lineárne. Ruleta sa s väčšou populáciou naopak *zhoršuje* (1125 → 1275). Vysvetlenie súvisí s elitizmom: počet elitných jedincov je pevne 2, takže ich podiel v populácii klesá z 10 % (populácia 20) na 1 % (populácia 200). Ruleta, ktorá sa spolieha takmer len na elitizmus, tak s rastúcou populáciou stráca jediný zdroj selekčného tlaku.

		Turnaj			Ruleta		
mestá	**najlepšia**	**avg**	**gap [%]**	**hit**	**avg**	**gap [%]**	**hit**
20	904,16	910,99	0,76	7/10	967,18	6,97	3/10
25	955,41	986,24	3,23	1/10	1052,60	10,17	0/10
30	1051,59	1082,15	2,91	1/10	1272,98	21,05	0/10
35	1099,19	1118,59	1,76	1/10	1388,65	26,33	0/10
40	1142,44	1164,19	1,90	1/10	1688,93	47,83	0/10

Table 8: Vplyv počtu miest (pre každý počet iná mapa; *najlepšia* je najlepšia známa trasa na danej mape)

Počet miest Turnaj drží priemernú trasu v rozmedzí 1–3 % od najlepšej známej trasy na všetkých mapách a pri 20 mestách ju nájde v 7 z 10 behov (tabuľka 8). Ruleta s rastúcim počtom miest zaostáva čoraz viac, z 7 % pri 20 mestách na 48 % pri 40 mestách. Pri väčšom priestore riešení sa slabý selekčný tlak prejaví ešte výraznejšie.

2.3.5 Zhrnutie

- Pre Problém obchodného cestujúceho s naším kódovaním je **turnajová selekcia jednoznačne lepšia ako ruleta**: rýchlejšie konverguje, dáva kratšie a stabilnejšie trasy a nepotrebuje elitizmus.

- Ruleta s fitness 1/dĺžka má takmer nulový selekčný tlak (46,7 % rodičov z horšej polovice). Konkurencieschopná je len s dostatočným elitizmom (aspoň 5 elitných jedincov).
- Pri turnaji existuje kompromis medzi rýchlosťou konvergencie (veľké k) a kvalitou a stabilitou výsledku (malé k). V našich experimentoch sa najlepšie osvedčilo $k = 2$.
- Doplnkové experimenty potvrdzujú voľbu baseline: mutácia 0,3–0,5 a populácia 50–100 sú dobrým kompromisom medzi kvalitou a časom.

3 Simulované žíhanie

Simulované žíhanie je metaheuristický algoritmus založený na lokálnom vyhľadávaní. Názov pochádza z procesu žíhania kovu: kov sa zahreje a potom sa pomaly ochladzuje, aby jeho atómy dosiahli stav s najnižšou energiou. V algoritme úlohu energie plní dĺžka trasy a úlohu teploty parameter, ktorý určuje, do akej miery je algoritmus ochotný prijať horšie riešenia.

Princíp fungovania algoritmu

V každom kroku algoritmus vytvorí susedný stav, t. j. malú zmenu aktuálnej trasy, a vypočíta rozdiel dĺžok $\Delta = L(\text{sused}) - L(\text{aktuálny})$

- Ak je sused lepší alebo $\Delta < 0$, algoritmus vždy prejde na neho.
- Ak je sused horší $\Delta > 0$, algoritmus prejde na neho s pravdepodobnosťou $P = e^{-\Delta/T}$ kde T je aktuálna teplota.

Úloha teploty

Pravdepodobnosť prijatia horšieho stavu závisí od dvoch vecí:

- **od teploty**: čím vyššia je T, tým častejšie algoritmus prijíma horšie stavy,
- **od toho, o koľko je stav horší**: čím väčšie je Δ, tým menšia je pravdepodobnosť.

Teplota sa postupne znižuje podľa **chladiaceho plánu**. Algoritmus začína s teplotou T_0, pri každej teplote vykoná daný počet krokov a potom ju zníži: $T \leftarrow \alpha \cdot T$, kde $0 < \alpha < 1$. Algoritmus končí, keď teplota klesne pod $T_{\min}$.

Algoritmus tak prechádza dvoma fázami:

1. **Na začiatku** (vysoká T) často prijíma horšie stavy a voľne prehľadáva priestor riešení.
2. **Na konci** (nízka T) prijíma horšie stavy len veľmi zriedka a správa sa takmer ako obyčajné lokálne prehľadávanie, teda už len vylepšuje nájdené riešenie.

Prečo to pomáha nájsť globálne minimum

Obyčajné lokálne prehľadávanie (hill climbing) prijíma len lepšie stavy, preto skončí v prvom lokálnom minime. Možnosť dočasne zhoršiť riešenie umožňuje simulovanému žíhaniu **uniknúť z lokálneho minima** a dostať sa do lepšieho lokálneho alebo do globálneho minima.

Uchovanie najlepšieho riešenia

Keďže algoritmus prijíma aj horšie stavy, aktuálny stav na konci nemusí byť najlepší zo všetkých nájdených. Algoritmus si preto zvlášť **pamätá najlepší nájdený stav** a vráti práve ten, aj keď na konci skončil v horšom lokálnom minime.

3.1 Nastavenie experimentov

Spoločné nastavenia

- **Mapy:** používajú sa *tie isté mapy* ako pri genetickom algoritme (rovnaký generátor a seed `MAP_SEED = 42`), konkrétne mapy s 20, 30 a 40 mestami. Výsledky oboch algoritmov sú preto priamo porovnateľné.
- **Opakovania:** každá konfigurácia sa spúšťa 10-krát so seedmi $0, \ldots, 9$. Uvádzané hodnoty sú priemery cez týchto 10 behov.
- **Počiatočný stav:** náhodná permutácia miest.
- **Susedný stav:** inverzia náhodného úseku trasy (ťah 2-opt), rovnako ako mutácia v GA.
- **Prijatie suseda:** lepší alebo rovnaký sused sa prijme vždy, horší s pravdepodobnosťou $P = e^{-\Delta/T}$.
- **Chladiaci plán:** geometrický. Pri každej teplote sa vykoná `steps_per_t` krokov, potom sa teplota zníži ($T \leftarrow \alpha \cdot T$). Algoritmus končí, keď $T < T_{\min}$.
- **Dĺžka behu je deterministická.** Na rozdiel od GA nemá simulované žíhanie kritérium patience.
- **Algoritmus si pamätá najlepší nájdený stav** a na konci vracia ten, nie aktuálny stav.

Základná konfigurácia (baseline)

V experimentoch sa vždy mení iba jeden parameter, ostatné ostávajú na hodnotách z tabuľky 9.

Parameter	Hodnota
Počiatočná teplota T_0	300
Koeficient chladenia α	0,95
Počet krokov na teplotu (`steps_per_t`)	100
Konečná teplota $T_{\min}$	0,1
Počet teplotných úrovní	≈ 156
Celkový počet iterácií	$\approx 15\,600$

Table 9: Základná konfigurácia simulovaného žíhania

Experimenty

1. **Vplyv parametrov chladiaceho plánu.** Postupne sa menia tri parametre, každý na mapách s 20, 30 a 40 mestami (tabuľka 10). Spolu ide o 13 unikátnych konfigurácií na mapu, teda $3 \cdot 13 \cdot 10 = 390$ behov.

Parameter	Testované hodnoty	Počet iterácií
α	0,8; 0,9; **0,95**; 0,99; 0,995	$\approx 3\,600$ – $160\,000$
T_0	10; 50; **300**; 1000; 5000	$\approx 9\,000$ – $21\,100$
`steps_per_t`	10; 50; **100**; 500; 1000	$\approx 1\,560$ – $156\,000$

Table 10: Testované hodnoty parametrov (tučne baseline)

   Parametre α a `steps_per_t` menia dĺžku behu zhruba stonásobne. T_0 ju mení len málo, pretože počet úrovní závisí od T_0 len logaritmicky.

2. **Kvalita vs. výpočtová cena.** Keďže každý parameter mení aj počet iterácií, všetky konfigurácie sa vykreslia do jedného grafu: priemerná výsledná dĺžka trasy v závislosti od počtu iterácií (logaritmická os). Vidno tak, či zlepšenie spôsobil samotný parameter, alebo len dlhší beh.

3. **Priebeh chladenia** (30 miest, sweep α). Pre každé α sa sleduje teplota a podiel prijatých ťahov na každej teplotnej úrovni (priemer z 10 behov). Pre jeden baseline beh (seed 0) sa navyše sleduje dĺžka aktuálnej a najlepšej doteraz nájdenej trasy.

4. **Najlepšie trasy** baseline konfigurácie vykreslené na mapách s 20, 30 a 40 mestami.

Sledované metriky

Pre každú konfiguráciu sa z 10 behov počítajú:

- **avg, std, best, worst**: priemer, smerodajná odchýlka, minimum a maximum dĺžky výslednej trasy,
- **gap** [%]: o koľko percent je priemerná trasa dlhšia ako najlepšia trasa, ktorú simulované žíhanie našlo na danej mape v ktoromkoľvek behu,
- **iterácie**: celkový počet krokov chladiaceho plánu,
- **čas**: priemerný čas jedného behu v sekundách,
- **hit**: v koľkých z 10 behov algoritmus našiel najlepšiu známu trasu.

3.2 Výsledky a porovnanie

Najlepšie trasy, ktoré simulované žíhanie našlo v ktoromkoľvek behu, majú dĺžku 904,16 (20 miest), 1051,59 (30 miest) a 1124,39 (40 miest). Voči nim sa počíta gap a hit.

3.2.1 Vplyv parametrov chladiaceho plánu

α	iterácie	20 miest	30 miest	40 miest	hit (20)
0,8	3 600	936,56 ± 34,18	1082,24 ± 18,10	1207,82 ± 40,73	3/10
0,9	7 600	918,43 ± 16,25	1084,30 ± 20,01	1169,22 ± 33,20	4/10
0,95	15 700	910,83 ± 9,20	1079,87 ± 20,54	1155,84 ± 20,61	6/10
0,99	79 700	904,16 ± 0,00	1060,65 ± 10,36	1144,54 ± 10,68	10/10
0,995	159 800	904,16 ± 0,00	1057,46 ± 7,47	1135,81 ± 9,12	10/10

Table 11: Vplyv koeficientu chladenia α (avg ± std z 10 behov)

steps_per_t	iterácie	20 miest	30 miest	40 miest	hit (20)
10	1 570	919,80 ± 10,36	1140,59 ± 50,04	1388,21 ± 52,57	2/10
50	7 850	919,47 ± 16,41	1076,56 ± 23,16	1171,66 ± 23,99	4/10
100	15 700	910,83 ± 9,20	1079,87 ± 20,54	1155,84 ± 20,61	6/10
500	78 500	904,16 ± 0,00	1060,54 ± 6,05	1133,11 ± 6,58	10/10
1000	157 000	904,16 ± 0,00	1057,36 ± 5,86	1139,70 ± 7,17	10/10

Table 12: Vplyv počtu krokov na teplotu (avg ± std z 10 behov)

T_0	iterácie	20 miest	30 miest	40 miest	hit (20)
10	9 000	927,92 ± 25,94	1075,73 ± 23,14	1184,70 ± 17,87	2/10
50	12 200	913,39 ± 14,02	1069,70 ± 17,54	1159,70 ± 14,41	5/10
300	15 700	910,83 ± 9,20	1079,87 ± 20,54	1155,84 ± 20,61	6/10
1000	18 000	912,55 ± 11,50	1070,63 ± 15,83	1153,09 ± 17,23	5/10
5000	21 100	911,15 ± 9,00	1069,84 ± 18,22	1161,29 ± 27,64	5/10

Table 13: Vplyv počiatočnej teploty T_0 (avg ± std z 10 behov)

- **Koeficient chladenia** α (tabuľka 11). Pomalšie chladenie dáva kratšie a stabilnejšie trasy na všetkých mapách. Pri 20 mestách nájde $\alpha \geq 0{,}99$ najlepšiu známu trasu v každom behu (std = 0). Pri 40 mestách sa priemer zlepší z 1208 ($\alpha = 0{,}8$) na 1136 ($\alpha = 0{,}995$). Zlepšenie má však klesajúci výnos: prechod z 0,99 na 0,995 zdvojnásobí čas, ale pri 30 mestách skráti trasu len o 3 jednotky (1060,65 → 1057,46).

- **Počet krokov na teplotu** (tabuľka 12) sa správa veľmi podobne ako α. Pri 10 krokoch algoritmus na žiadnej teplote nestihne dostatočne prehľadať okolie a výsledok je zlý (40 miest: 1388, gap 23 %). Od 500 krokov sa výsledok už nezlepšuje: pri 40 mestách je 1000 krokov dokonca mierne horších (1139,70 vs. 1133,11), čo je v rámci šumu.

- **Počiatočná teplota** T_0 (tabuľka 13) má najmenší vplyv. Výrazne horšia je len $T_0 = 10$ (20 miest: 928, 40 miest: 1185), pri ktorej algoritmus od začiatku prijíma málo horších ťahov a málo prehľadáva. Pre $T_0 \geq 50$ sú rozdiely v rámci smerodajnej odchýlky. Už pri $T_0 = 300$ sa prijíma približne 90 % ťahov (obr. 8), takže vyššia teplota pridá len ďalšie kroky náhodnej prechádzky. Zároveň mení počet iterácií len málo (9 000 – 21 100), lebo počet úrovní závisí od T_0 len logaritmicky.

3.2.2 Kvalita vs. výpočtová cena

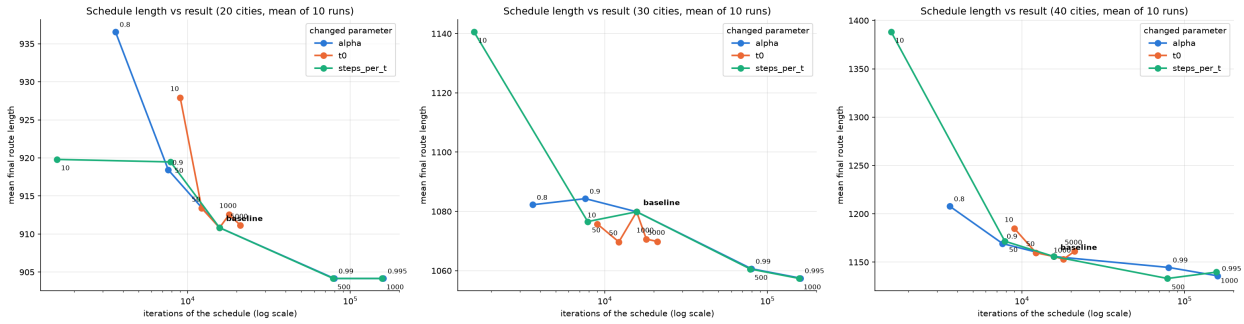


Figure 7: Priemerná výsledná dĺžka trasy v závislosti od počtu iterácií chladiaceho plánu (logaritmická os). Farba označuje menený parameter.

Graf 7 ukazuje, že **o kvalite rozhoduje hlavne celkový počet iterácií**, nie to, ktorým parametrom bol dosiahnutý. Krivky pre α a `steps_per_t` sa takmer prekrývajú. Napríklad pri 30 mestách dáva $\alpha = 0{,}99$ (79 700 iterácií) priemer 1060,65 a `steps_per_t` = 500 (78 500 iterácií) priemer 1060,54. Parameter T_0 mení dĺžku behu len málo, preto jeho body ležia v úzkom pásme okolo baseline.

Pri 20 mestách stačí na spoľahlivé nájdenie najlepšej trasy približne 80 000 iterácií (0,25 s). Pri väčších mapách sa trasa zlepšuje aj ďalej, ale stále pomalšie. Baseline (15 700 iterácií, približne 0,05 – 0,07 s) je kompromis: je o 1 – 3 % horší ako najdlhšie behy, no približne desaťkrát rýchlejší.

3.2.3 Priebeh chladenia

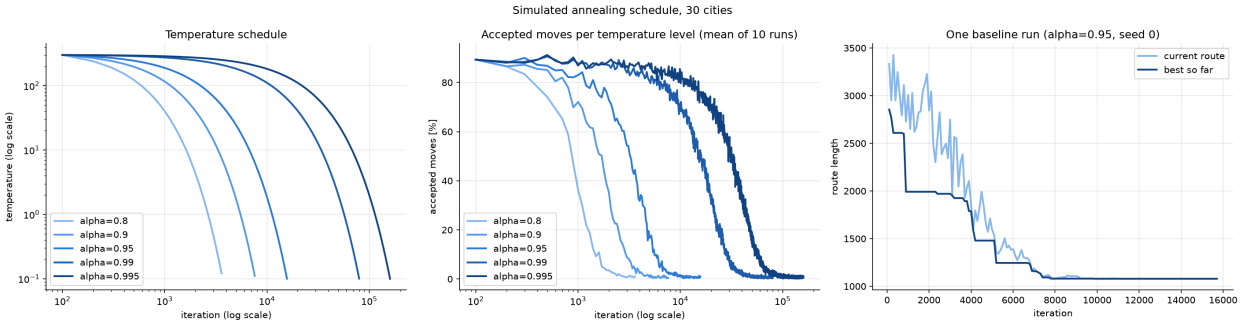


Figure 8: Teplota (vľavo), podiel prijatých ťahov na teplotnej úrovni (v strede, priemer z 10 behov) a priebeh jedného baseline behu (vpravo), 30 miest

- **Podiel prijatých ťahov** (obr. 8 v strede) ukazuje dve fázy algoritmu. Na začiatku sa pri všetkých α prijíma približne 90 % ťahov, algoritmus sa teda takmer náhodne pohybuje priestorom riešení. S klesajúcou teplotou podiel prudko klesne až k nule a algoritmus sa zmení na lokálne prehľadávanie. Čím je α väčšie, tým neskôr tento prechod nastane a tým dlhšie algoritmus prehľadáva.
- **Jeden baseline beh** (vpravo) zobrazuje rozdiel medzi aktuálnou a najlepšou trasou. Na začiatku aktuálna trasa výrazne kolíše (2300 – 3400), pretože algoritmus často prijíma horšie stavy. Najlepšia nájdená trasa sa zlepšuje skokovo. Okolo 8000. iterácie sa aktuálna trasa ustáli na najlepšej a ďalej sa už nemení. Pri baseline nastavení teda približne polovica iterácií pripadá na fázu, v ktorej sa takmer nič neprijíma. To naznačuje, že $T_{\min}$ by mohla byť vyššia bez straty kvality.
- Pamätanie si najlepšieho stavu je potrebné: počas prvej polovice behu je aktuálna trasa často o stovky jednotiek horšia ako najlepšia nájdená.

3.2.4 Najlepšie trasy

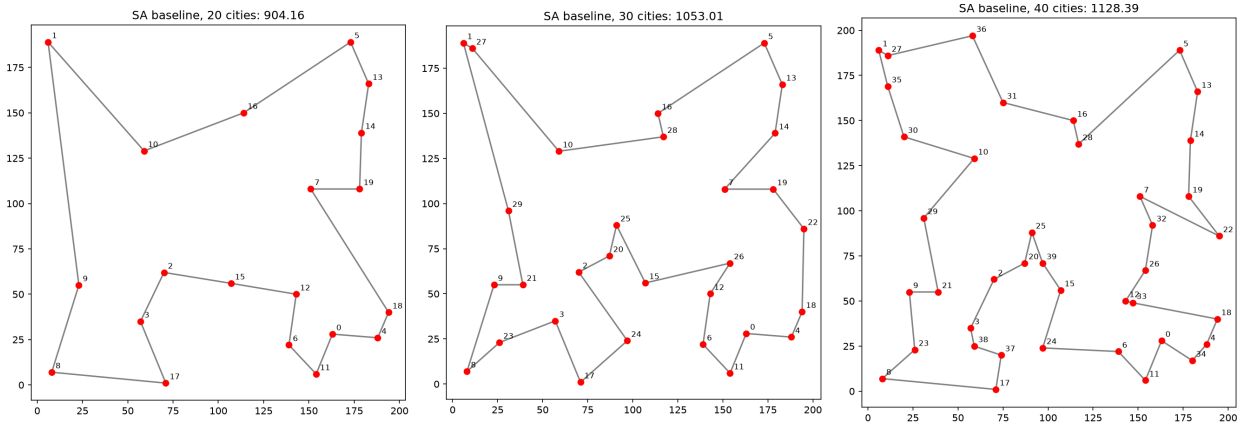


Figure 9: Najlepšia trasa baseline konfigurácie na mapách s 20, 30 a 40 mestami

Baseline konfigurácia našla pri 20 mestách najlepšiu známu trasu (904,16). Pri 30 a 40 mestách je jej najlepšia trasa (1053,01 a 1128,39) len o 0,1 a 0,4 % dlhšia ako najlepšia trasa nájdená dlhšími plánmi. Na trasách nevidno kríženia hrán.

3.2.5 Zhrnutie

- Kvalitu výsledku určuje hlavne **celková dĺžka chladiaceho plánu**. Pomalšie chladenie (α) aj viac krokov na teplotu zlepšujú trasu aj stabilitu, no s klesajúcim výnosom.
- Počiatočná teplota má malý vplyv, pokiaľ nie je príliš nízka. $T_0 = 300$ už zaručuje približne 90 % prijatých ťahov na začiatku.
- Pri 20 mestách nájde simulované žíhanie s dostatočne dlhým plánom najlepšiu známu trasu v každom behu.

4 Záver

		GA (turnaj)		SA	
mestá	**najlepšia známa**	**avg**	**čas [s]**	**avg**	**čas [s]**
20	904,16	910,99	0,26	910,83	0,05
30	1051,59	1082,15	0,39	1079,87	0,06
40	1124,39	1164,19	0,77	1155,84	0,07

Table 14: Porovnanie GA a SA pri baseline nastaveniach

Pri GA rozhoduje hlavne metóda výberu rodičov: turnaj je jednoznačne lepší ako ruleta, ktorá má takmer nulový selekčný tlak a funguje len vďaka elitizmu. Pri SA rozhoduje hlavne celková dĺžka chladiaceho plánu.

Oba algoritmy dávajú podobne dlhé trasy, SA je však 5 – 10-krát rýchlejšie a pri 40 mestách našlo kratšiu trasu (1124,39) ako ktorýkoľvek beh GA (1142,44). Pre TSP tejto veľkosti je preto vhodnejšie simulované žíhanie.